

Introducción del proyecto

- En la actualidad, la integración de datos multimodales (imágenes y texto) es clave para sistemas robustos de recomendación y clasificación.
- Ejemplo: Moda, análisis de productos, satisfacción de clientes.

Objetivo

- Construir un sistema capaz de combinar características visuales y sentimentales para una predicción conjunta.

Alcance

- Implementar y evaluar modelos independientes.
- Integrar ambos modelos en un clasificador final.

CNN — Clasificación de imágenes

Arquitectura


- Dos bloques: Conv2D + MaxPooling.
- Flatten y capa densa final.

Hiperparámetros

- Batch size: 64.
- Tasa de aprendizaje: Adam (default).
- Epochs: 5.

Accuracy entrenamiento: ~91%

```
Epoch 1/5  
750/750 ————— 46s 60ms/step - accuracy: 0.7471 - loss: 0.7147 - val_accuracy: 0.8632 - val_loss: 0.3734  
Epoch 2/5  
750/750 ————— 44s 58ms/step - accuracy: 0.8749 - loss: 0.3399 - val_accuracy: 0.8837 - val_loss: 0.3217  
Epoch 3/5  
750/750 ————— 81s 57ms/step - accuracy: 0.8918 - loss: 0.2936 - val_accuracy: 0.9025 - val_loss: 0.2746  
Epoch 4/5  
750/750 ————— 43s 57ms/step - accuracy: 0.9069 - loss: 0.2506 - val_accuracy: 0.8998 - val_loss: 0.2674  
Epoch 5/5  
750/750 ————— 82s 57ms/step - accuracy: 0.9130 - loss: 0.2323 - val_accuracy: 0.9079 - val_loss: 0.2568
```



LSTM — Análisis de texto

Análisis de Sentimientos de Reseñas de Películas con LSTM

Arquitectura

- Embedding layer, convierte palabras en vectores numéricos densos
- LSTM con 64 unidades.
- Dense con sigmoide.

Accuracy: ~94%

```
Epoch 1/3
313/313 ————— 85s 264ms/step - accuracy: 0.6963 - loss: 0.5389 - val_accuracy: 0.8574 - val_loss: 0.3384
Epoch 2/3
313/313 ————— 141s 261ms/step - accuracy: 0.8993 - loss: 0.2563 - val_accuracy: 0.8702 - val_loss: 0.3122
Epoch 3/3
313/313 ————— 88s 282ms/step - accuracy: 0.9412 - loss: 0.1665 - val_accuracy: 0.8710 - val_loss: 0.3502
Downloading data from https://storage.googleapis.com/tensorflow/tf-keras-datasets/imdb\_word\_index.json
1641221/1641221 ————— 0s 0us/step
```

Integración multimodal

Flujo del sistema

- Extraer embeddings de CNN y LSTM.
- Fusionar (concatenar).
- Clasificador final con capas densas.

Justificación

- Combina visión y texto, usando lo mejor de cada modalidad.

```
[14] 1 # Evaluar modelo final sobre mismo subset (ejemplo simple)
      2 final_eval = final_model.evaluate(combined_features, sample_labels, verbose=0)
      3 print(f"Accuracy del modelo fusionado (subset): {final_eval[1]*100:.2f}%")
      4
```

⇒ Accuracy del modelo fusionado (subset): 94.00%



Resumen comparativo de modelos

Modelo	Dataset	Tarea	Accuracy aprox. (subset)
CNN	Fashion-MNIST	Clasificación imágenes	~92% (validación)
LSTM	IMDB	Análisis de sentimiento	~85% (validación)
Fusionado	Ambos	Predicción conjunta	~94%

Análisis y comparación

- CNN: Excelente para detalles visuales.
- LSTM: Bueno para contexto textual.
- Fusionado: Mayor robustez, combina evidencias.
- Fortalezas: Complementariedad de datos.

Conclusiones y mejoras

Resumen

- Se cumplió el objetivo: integración multimodal funcionando.

Propuestas

- Aumentar datos y epochs.

Limitaciones

- Dataset reducido en la fusión.

Gracias